

MasterClass_AI for Document Understanding

Khai giảng Thứ 2, 01.06.2026

Đăng ký tại: <https://forms.gle/YHyRn84QSCmBdb448>

Đối tượng học: - AI Engineer / ML Engineer muốn đi sâu vào OCR, Document AI, Multimodal AI - Backend Engineer muốn build hệ thống AI production-ready - Data Scientist muốn mở rộng sang LLM/VLM & Document Understanding - Sinh viên năm cuối / Fresher AI đã có nền tảng ML/DL cơ bản - Các bạn đang làm Banking, Fintech, Automation, eKYC, Invoice Processing, Intelligent Document Processing (IDP) - Người muốn build sản phẩm AI xử lý chứng từ, hóa đơn, PDF, biểu mẫu thực tế	Yêu cầu đầu vào - Biết Python cơ bản - Có kiến thức nền tảng Machine Learning / Deep Learning - Hiểu cơ bản về training/inference workflow là một lợi thế - Đã từng dùng PyTorch/HuggingFace là điểm cộng (không bắt buộc) - Có tinh thần tự thực hành & đọc tài liệu kỹ thuật	Mục tiêu chương trình - Hiểu toàn bộ pipeline của một hệ thống Document AI hiện đại - Nắm được cách xây dựng OCR pipeline từ detection → recognition → extraction - Hiểu cách hoạt động của LayoutLM, LLM, Vision Language Model trong Document Understanding - Biết cách fine-tune model cho bài toán OCR/KIE thực tế - Biết cách đánh giá hệ thống bằng CER/WER/F1/Latency/Throughput - Hiểu tư duy thiết kế AI system theo hướng production-ready - Có khả năng triển khai AI model serving với ONNX, Triton, vLLM, FastAPI	Sau chương trình, học viên sẽ nắm vững - OCR pipeline thực tế cho document/hóa đơn/chứng từ - Key Information Extraction (KIE) với LayoutLM & LLM - Fine-tuning LLM/VLM cho bài toán Document AI - Xây dựng hệ thống end-to-end từ ảnh → structured JSON/API - AI serving & deployment cho production environment - Tư duy thiết kế và tối ưu hệ thống Document AI hiện đại - Quy trình triển khai Document Understanding trong Banking/Fintech/Enterprise AI	Note: - Dataset xuyên suốt: SROIE - SROIE: ~1.000 ảnh hóa đơn, 4 trường KIE Lab (google colab server) API FastAPI - Conditional: Qwen fine-tune chỉ khi zero-shot F1 < 0.85
Mentor – Ths. Nguyễn Việt Hoài - Senior AI Engineer tại Vinsmart Future - Machine Learning Team Lead @ GMO-Z.com RUNSYSTEM 5+ năm kinh nghiệm trong lĩnh vực AI xử lý số hoá giấy tờ - Từng làm việc tại FPT Smart Cloud, Sun Asterisk - Thành thạo: Triton, FastAPI, Onnx, LangChain, LangGraph, vLLM - Tác giả nhiều mô hình OCR, Smart Agent - Best Paper Award tại MAPR 2023 - GitHub: github.com/hoainv99 - Viblo: https://viblo.asia/u/HoaiNV - LinkedIn: Nguyễn Việt Hoài				

Lịch học (20h-22h)	Buổi	Nội dung	Output	Mục tiêu
PHASE 1 — CÁC MÔ HÌNH AI TRUYỀN THÔNG				
Thứ 2 (Ngày 01/06)	Buổi 1: Tổng quan Pipeline & Text Detection	- Giới thiệu Document Understanding: pipeline tổng thể, ứng dụng thực tế - Giới thiệu SROIE: cấu trúc thư mục, format annotation (bbox + text + KIE label) - Layout Analysis (lý thuyết): DocLayout-YOLO — YOLO-based, phân vùng text/table/figure/title - Text Detection — Lý thuyết so sánh: - DB-Net: real-time, differentiable binarization - MixNet: mixed depthwise convolution, multi-scale feature fusion Lab: (1) Chạy DB-Net pretrained trên 50 ảnh SROIE test → tính P/R/F1 (2) Fine-tune MixNet cho text detection trên SROIE train set - Chuẩn bị annotation (polygon bbox) - Train với lr warmup + augmentation - So sánh F1: MixNet fine-tuned vs DB-Net pretrained	- Notebook: detection_benchmark.ipynb - Checkpoint: mixnet_sroie_finetuned.pth - Bảng so sánh F1/Precision/Recall: DB-Net pretrained vs MixNet fine-tuned - Visualization: bbox overlay trên 10 ảnh SROIE mẫu - Report ngắn (markdown): nhận xét error case, failure mode	Nắm nguyên lý & điểm khác biệt DB-Net / MixNet; fine-tune thành công MixNet; có bảng so sánh F1 detection
Thứ 5 (Ngày 04/06)	Buổi 2: Text Recognition (OCR)	- CRNN: CNN + BiLSTM + CTC — kiến trúc baseline - TransformerOCR: encoder-decoder Transformer, cross-attention (lý thuyết + demo) - PARSeq: Permuted Autoregressive Sequence — permutation language model, multi-order prediction - So sánh CTC vs Attention vs PARSeq: accuracy, speed, xử lý chữ cong/mờ/bị che Lab: (1) Crop word images từ SROIE bbox (dùng output MixNet buổi 1) (2) Fine-tune PARSeq trên word crops SROIE - baudm/parseq pretrained → fine-tune - Evaluate CER/WER (3) Demo TransformerOCR inference (4) Bảng so sánh CER/WER: CRNN baseline / TransformerOCR / PARSeq fine-tuned	- Notebook: ocr_finetune_parseq.ipynb - Checkpoint: parseq_sroie_finetuned.ckpt - Dataset: word_crops/ (từ MixNet bbox buổi 1) + labels.txt - Bảng CER/WER: CRNN / TransformerOCR / PARSeq fine-tuned - OCR result JSON cho toàn bộ SROIE test (input cho buổi 3)	Fine-tune PARSeq thành công; hiểu permutation LM; có bảng so sánh CER/WER; output PARSeq là input cho KIE buổi 4 & 6
Thứ 2 (Ngày 08/06)	Buổi 3: Key Information Extraction (KIE) — Fine-tune LayoutLMv3	- NER trên tài liệu: BIO tagging, đặc trưng spatial + visual + text - LayoutLMv3: multi-modal pre-training, spatial-aware self-attention - So sánh LayoutLM v1 → v2 → v3 - SROIE KIE: 4 fields — company, date, address, total; metric: F1 per field + Exact Match Lab: (1) Chuẩn bị SROIE Task 3 → tokenize + align bbox với WordPiece (2) Fine-tune LayoutLMv3 (microsoft/layoutlmv3-base-uncased) - Input: OCR output thực từ PARSeq (buổi 2) - Config: batch size, lr, epoch, label smoothing (3) Evaluate: F1 per field; phân tích error case (4) Lưu model checkpoint → dùng lại trong FastAPI (buổi 9–10) → Kết quả = KIE backend #1 trong API	- Notebook: kie_layoutlmv3_finetune.ipynb - Checkpoint: layoutlmv3_sroie_kie.bin (dùng lại ở buổi 6–8) - Tokenized dataset + BIO labels aligned với bbox - Bảng F1 per field (company/date/address/total) + Exact Match - Error analysis: top 10 sai điển hình - KIE Backend #1 sẵn sàng cho API	Fine-tune LayoutLMv3 thành công; có F1 baseline; checkpoint sẵn sàng cho serving
PHASE 2: LLM & VISION-LANGUAGE MODEL				

Thứ 5 (Ngày 11/06)	Buổi 4: Nền tảng LLM & Fine-tune Qwen2.5-3B cho KIE	- Kiến trúc Transformer, Qwen2.5-3B: grouped query attention, RoPE, sliding window - Kỹ thuật fine-tuning: LoRA, QLoRA, PEFT; chat template, instruction format - Công cụ: HuggingFace Transformers, PEFT, TRL (SFTTrainer) - Zero-shot evaluation trước khi fine-tune: nếu đủ tốt → dừng, không cần fine-tune Lab — Qwen2.5-3B KIE trên SROIE: BUỔI C 1 — Zero-shot test: - Prompt: "Extract from this receipt text: {ocr_text}. Output JSON: {company, date, address, total}" → Evaluate F1 trên SROIE test set → Nếu Macro F1 ≥ 0.85: ghi nhận kết quả, bỏ qua fine-tune → Nếu F1 < 0.85: chuyển sang bước 2 BUỔI C 2 — Fine-tune (nếu cần): - Build instruction dataset từ SROIE train: OCR text (PARSeq) → JSON {4 fields} - Fine-tune Qwen2.5-3B-Instruct với QLoRA (4-bit) - Evaluate: F1, Exact Match, hallucination rate - Lưu LoRA adapter → dùng trong FastAPI (buổi 9–10) → Kết quả = KIE backend #2 trong API	- Notebook: qwen_kie_zeroshot_and_qlora.ipynb - Zero-shot result: JSON + F1 report (Nếu fine-tune) LoRA adapter: qwen25_3b_sroie_lora/ - Instruction dataset JSONL: sroie_kie_instructions.jsonl - Bảng F1 / Exact Match / hallucination rate - Decision log: zero-shot đạt/không đạt ngưỡng 0.85 - KIE Backend #2 sẵn sàng cho API	Đánh giá zero-shot Qwen2.5-3B; quyết định có fine-tune hay không dựa trên ngưỡng F1; có KIE backend #2 sẵn sàng
Thứ 2 (Ngày 15/06)	Buổi 5: Vision-Language Model (VLM): Lý thuyết	- Kiến trúc VLM: Vision Encoder (ViT/CLIP) + Connector + LLM Decoder - Model SOTA OCR: GLM-OCR, LightonOCR, Chandra-OCR, Nanonets-OCR - Ứng dụng Document AI: OCR-free KIE, Table understanding, Document QA - GLM-OCR, lightonOCR: VLM chuyên biệt cho document (tìm hiểu sâu glm-ocr) - Demo: zero-shot nanonets-ocr trên vài ảnh SROIE - Trade-off VLM vs traditional pipeline: accuracy, latency, cost, data Phần này chỉ lý thuyết + demo, không fine-tune	- Slide/notes lý thuyết VLM architecture - Notebook demo: vlm_zeroshot_demo.ipynb (GLM-OCR / NanonetsOCR) - Output JSON demo trên 5–10 ảnh SROIE - Bảng trade-off: VLM vs traditional pipeline (accuracy/latency/cost/data)	Hiểu kiến trúc VLM; phân tích được trade-off VLM vs pipeline; biết khi nào nên dùng VLM trong production
PHASE 3: SERVING & DEPLOYMENT				
Thứ 5 (Ngày 18/06)	Buổi 6: ONNX & Triton Inference Server	- ONNX: export PyTorch model → ONNX, kiểm tra graph (Netron), validate - Triton IS: kiến trúc, model repository, config.pbtxt, backends (onnxruntime, python) - HTTP/gRPC API với tritonclient Lab: - Export PARSeq (OCR) → ONNX → validate - Export LayoutLMv2 (KIE) → ONNX → validate - Deploy cả 2 lên Triton (onnxruntime backend) - Benchmark: PyTorch vs ONNX vs Triton (latency single request) - Chuẩn bị Qwen2.5-3B serve riêng bằng vLLM (xem buổi 9)	- File ONNX: parseq.onnx, layoutlmv3.onnx (đã validate bằng Netron) - Script export + validation: export_onnx.py - Triton model_repository/ với config.pbtxt cho 2 model - Bảng benchmark latency: PyTorch / ONNX Runtime / Triton - Notebook test Triton client (HTTP + gRPC)	Export thành công 2 model ONNX; deploy trên Triton; đo speedup latency; hiểu kiến trúc serving
Thứ 2 (Ngày 22/06)	Buổi 7: Triton Ensemble Pipeline + vLLM + FastAPI (Phần 1)	- Triton: Dynamic batching, Python Backend, Ensemble DAG - vLLM: PagedAttention, continuous batching — serve Qwen2.5-3B - FastAPI: async endpoint, Pydantic schema, dependency injection Lab: - Hoàn thiện Triton server backend - Build dockerfile, docker-compose - Bổ sung warmup model, pipeline	- Triton Ensemble DAG config (ensemble_model/config.pbtxt) - Python backend scripts (pre/post-processing) - vLLM server script serve Qwen2.5-3B + LoRA - Dockerfile + docker-compose.yml cho full stack - FastAPI skeleton: main.py, routers/, schemas.py (Pydantic) - Warmup scripts cho cả 2 model	Có Triton Ensemble pipeline chạy được; vLLM serve Qwen2.5-3B; FastAPI skeleton với routing 2 backend
Thứ 5 (Ngày 25/06)	Buổi 8: FastAPI hoàn chỉnh: Dual-Backend KIE API	- FastAPI nâng cao: async/await, background tasks, middleware CORS, error handling - Tích hợp Triton gRPC client + vLLM HTTP client vào FastAPI - Health check, model status endpoint - Swagger UI / ReDoc tự động - Logging, request tracing, response caching (tuỳ chọn) Lab: - Hoàn thiện FastAPI với đầy đủ 2 backend - Test với SROIE test images: - Gọi /kie?backend=layoutlmv2 → kết quả + latency - Gọi /kie?backend=qwen → kết quả + latency - Benchmark throughput: 10 concurrent requests × 2 backend - Demo Swagger UI: upload ảnh SROIE → chọn backend → xem JSON output	- FastAPI hoàn chỉnh: POST /kie?backend={layoutlmv3 qwen} - Health check + /models/status endpoints - Swagger UI / ReDoc auto-generated - Bảng benchmark throughput (10 concurrent × 2 backend) - Middleware: CORS, logging, error handler, request tracing - Video/GIF demo upload ảnh SROIE → JSON output	FastAPI hoàn chỉnh với 2 backend; test được cả hai; có bảng benchmark throughput/latency; Swagger UI demo được
PHASE 4: FINAL PROJECT				
Thứ 2 (Ngày 29/06)	Buổi 9: Capstone Project + Production Mindset	- Đề bài: Hệ thống Document Understanding end-to-end có API trên SROIE - Yêu cầu tối thiểu: - Layout Analysis: DocLayout-YOLO - OCR: MixNet (fine-tuned) + PARSeq (fine-tuned) - KIE: ít nhất 1 backend (LayoutLMv2 hoặc Qwen2.5-3B) - Serving: Triton Ensemble + vLLM (ít nhất 1) - FastAPI: POST /kie với option chọn backend - Report: F1 per field, E2E latency, throughput - Mentor hỗ trợ debug kiến trúc, review code	- Repo Git đầy đủ: src/, notebooks/, configs/, docker/ - Hệ thống E2E chạy được: Layout → OCR → KIE → FastAPI - ít nhất 1 KIE backend deployed (Triton hoặc vLLM) - README.md: kiến trúc, cách chạy, kết quả - Report số liệu: F1 per field, E2E latency, throughput - Review note từ giảng viên	Hệ thống chạy E2E; API FastAPI hoạt động với ít nhất 1 backend; report số liệu đầy đủ
Thứ 5 (Ngày 02/07)	Buổi 10: Demo, Trình Bày & Tổng Kết	- Demo live qua Swagger UI hoặc frontend: - Bảo vệ kiến trúc (10–15 phút/nhóm) - Q&A phản biện từ giảng viên - Tổng kết: - Recap toàn module qua lens SROIE → FastAPI - Xu hướng mới: GOT-OCR 2.0, DocOwl2, Document Agent - Roadmap: Multimodal LLM fine-tuning, RAG + Doc AI, agentic pipeline	- Slide trình bày bài tập lớn (10–15 phút) - Demo video hoặc live qua Swagger UI - Q&A transcript + feedback từ giảng viên - Roadmap học tập cá nhân (markdown) - Reference list: GOT-OCR 2.0, DocOwl2, Document Agent - Tổng kết module	Trình bày & bảo vệ thành công; có roadmap học tập rõ ràng; nhận feedback chuyên sâu

FINAL PROJECT
(Presentation)

Production-Ready Document Understanding System

- Yêu cầu tối thiểu:**
Layout Analysis: DocLayout-YOLO
OCR: MixNet (fine-tuned) + PARSeq (fine-tuned)
KIE: ít nhất 1 backend (LayoutLMv2 hoặc Qwen2.5-3B)
Serving: Triton Ensemble + vLLM (ít nhất 1)
FastAPI: POST /kie với option chọn backend
Report: F1 per field, E2E latency, throughput
- Output:**
- Repo Git đầy đủ: src/, notebooks/, configs/, docker/
 - Hệ thống E2E chạy được: Layout → OCR → KIE → FastAPI
 - ít nhất 1 KIE backend deployed (Triton hoặc vLLM)
 - README.md: kiến trúc, cách chạy, kết quả
 - Report số liệu: F1 per field, E2E latency, throughput